

Hilal Hoca toplantı hazırlığı

Donör-farkında, çok modaliteli tek hücre perturbation tahmini. Toplantıya girmeden önce dördümüzün aynı şeyi anlatabilmesi, hocanın sorularına hazır olması ve toplantıdan net kararlarla çıkması için.

EKİP

Berk · Atay · Alperen · Bengisu

DANIŞMAN

Hilal Kazan

TARİH

1 Ekim 2026

1 Toplantı özeti

Amaç: konuyu netleştirmek, ilk ayın işini ve GPU erişimini konuşmak.

TEK CÜMLELİK FİKİR

Yeni bir hastanın perturbe edilmemiş örneğinden, o hastanın hücrelerinin bir ilaca veya gen susturmaya vereceği cevabı RNA, protein ve kromatin katmanlarında birlikte tahmin etmek.

Önce var olan yöntemleri (MultiPert, MultiFlow) aynı koşullarda basit yöntemlerle karşılaştıracğız. Sonra donör bilgisini kullanan bir model deneyeceğiz.

Önerilen akış (yaklaşık 20 dakika)

DAKİKA	KONU	ANLATAN
0-2	Teşekkür ve bugünün amacı "Konuyu seçtik, ilk taramayı yaptık, yön konusunda onayınızı almak istiyoruz."	Berk
2-6	Problem ve boşluk Multimodal modeller yeni ve değerlendirmeleri dar. Donör bilgisini kullanan tek yöntem CellFlow ve yalnızca RNA ile çalışıyor.	Bengisu
6-10	İki makale ve nasıl kıyaslayacağımız MultiPert (RNA+protein) ve MultiFlow (RNA+ATAC). Ortak veri, ortak split, ortak metrik.	Alperen
10-14	Yaptıklarımız ve ön sonuçlar pertbench paketi, 3 veri üzerinde ilk tablo, Papalex'i'deki "donör"ün aslında replikat çıkması.	Atay
14-20	Kararlar ve sorular Hangi veriyle başlıyoruz, GPU nereden, raporlama sıklığı, beklenen çıktı (tez / makale).	Hepimiz

NAZİK BİR DÜZELTME


Hoca mailinde "donör bilgisini dahil eden bir yöntem yok gibi" dedi. Aslında CellFlow bunu yapıyor, ama yalnızca RNA ile. Bunu şöyle söyleyelim: "Baktığımızda CellFlow'un donörü kontrol ortalamasıyla temsil ettiğini gördük. Ama multimodal tarafta bunu yapan bir çalışma bulamadık. Sizin gösterdiğiniz iki boşluğun kesişimi hâlâ açık görünüyor."

2 Konu özeti

Toplantıda hepimizin rahatça anlatabilmesi gereken kısım.

Perturbation prediction ne?

Bir grup hücreyi ikiye ayırıyoruz. Bir grup olduğu gibi kalıyor (**kontrol**), diğerine bir **perturbation** uyguluyoruz: bir ilaç, bir sitokin ya da CRISPR ile bir genin susturulması. Sonra iki grubun her hücrelerini tek tek ölçüyoruz. Model, ölçmediğimiz durumlar için cevabı tahmin etmeye çalışıyor.



Şekil 1. Görev: kontrol profili + perturbation → perturbe profil. Bizim eklediğimiz iki şey: çıktı birden fazla katmanda ve girdi yeni bir donöre ait.

"Multimodal" ne demek?

Aynı hücrede birden fazla molekül katmanının ölçülmesi. İlacın dozu, zamanı veya genlerin birbirini etkilemesi multimodalite değil. Doz ve zaman deney *koşulu*, genler arası etkileşim ise modelin öğrenmeye çalıştığı şey.

RNA	Protein	Kromatin
scRNA-seq	CITE-seq / ADT	ATAC / Multiome
Hangi gen ne kadar ifade ediliyor. Binlerce özellik. Alandaki modellerin neredeyse hepsi sadece bunu kullanıyor.	Hücre yüzeyindeki proteinler, antikorla ölçülüyor. Genelde 4–200 özellik. İlacın asıl hedefi çoğu zaman bu katman.	DNA'nın hangi bölgeleri açık. On binlerce "peak". Gen ifadesinin bir adım öncesini gösteriyor.

Neden önemli: bir perturbation RNA'yı az değiştirip proteini çok değiştirebilir. Frangieh 2021'de bazı direnç genlerinin etkisi RNA'da görünmeyip sadece proteinde görünüyor. Yalnızca RNA'ya bakan model bu etkiyi kaçırr.

Genelleme eksenleri: ne tahmin ediyoruz?

EKSEN	SORU	DURUM
Görülmemiş perturbation	Hiç ölçülmemiş bir geni susturursak ne olur?	En zor. Derin modeller basit lineer modelleri çoğu zaman geçemiyor (Ahlmann-Eltze 2025).
Görülmemiş hücre tipi	T hücresindeki etkiyi biliyoruz, B hücresinde ne olur?	Orta. MultiFlow'un ana görevi bu.
Görülmemiş donör	Yeni hastanın kontrol örneği var, cevabı ne olur?	Klinik açıdan en anlamlı olanı. Bizim odağımız.

Neden basit baseline'lar bu kadar önemli?

En basit tahmin şu: "bu perturbation diğer donörlerde ortalama ne yaptıysa, yeni donörde de onu yapar". Bu `PerturbationMean` modeli, ve çoğu zaman şaşırtıcı derecede iyi. Bir derin model bunu geçemiyorsa işe yaramıyor demektir. 2025'teki büyük benchmark'lar, yayınlanmış birçok modelin bu testi geçemediğini gösterdi. Bizim benchmark'ımız bu karşılaştırmayı her zaman yapacak.

Ayrıca metrik tuzağı var: tahmin ve gerçek profil arasındaki ham Pearson korelasyonu, "hiçbir şey değişmez" diyen modelde bile $\sim 0,99$ çıkıyor. Bu yüzden **kontrolle göre değişimi (delta)** ölçüyoruz: `pearson_delta`, en çok değişen 20 gende hata (`mse_top20`) ve değişimin yönünü doğru bilme oranı.

3 Hocanın gönderdiği iki makale

Her birini 30 saniyede anlatabilmeliyiz.

	MultiPert Zhao vd., PLOS Comput Biol, Mart 2026	MultiFlow Wang vd. (Yale/Stanford), bioRxiv, Ağustos 2026
Modalite	RNA + protein; ek deneylerde ATAC	RNA + ATAC
Temel fikir	Her modaliteye ayrı encoder ve ortak latent uzay. Adversarial ağ modaliteleri hizalıyor, dikkat mekanizması birleştiriyor. Perturbation embedding'i GEARS'ın gen grafiğinden geliyor.	Flow matching: gürültüden hedef hücre durumuna giden bir "akış" öğreniliyor. İki modalite için iki akış var ve bunlar birbirine bilgi aktarıyor.
Veri	THP-1 ECCITE-seq (9 KO, 4 protein); böbrek CaRPool-seq (7 pert., 7 protein)	Perturb-multiome (133 bin hücre, 10 hücre tipi, 19 TF)
Görev	Ağırlıklı görülmüş perturbation'lar; ek olarak leave-one-out	Görülmemiş hücre tipi
Zayıf yön	Çok küçük veri (4–7 protein, 7–9 perturbation), donör eksenini yok, lineer/ortalama baseline'larla karşılaştırma yok.	Tek veri kaynağı, tam 2 modaliteye göre tasarlanmış, donör eksenini yok.
Kod	github.com/MengyuanZhao/MultiPert	github.com/liuq-lab/MultiFlow

Farklı modalitelerle çalışan iki modeli nasıl kıyaslarız?

Bengisu'nun sorusu. Hoca da muhtemelen soracak.

- Ortak veri.** MultiPert makalesinde RNA+ATAC deneyi de var. MultiFlow da MultiPert'i kendi verisinde baseline olarak çalıştırmış. Yani RNA+ATAC verisinde ikisi yan yana koşabiliyor. RNA+protein için MultiFlow'un ATAC encoder'ı yerine protein encoder'ı takmayı deneyeceğiz. Mimari buna izin veriyor gibi, ama kodu okuyarak doğrulamamız gerekiyor.
- Ortak modalite.** İkisi de RNA tahmin ediyor. RNA metriklerini doğrudan karşılaştırabiliriz. İkinci modaliteyi ayrıca raporlarız.
- Ortak split ve metrik.** İkisini de aynı görevlerde (görülmemiş perturbation, hücre tipi, donör) ve aynı kodla skorlarız. Yanlarına basit baseline'ları da koyarız.

4 Yaptıklarımız ve ön sonuçlar

Toplantıda Atay anlatacak, herkes özünü bilmeli.

- **Literatür taraması:** 15 civarında yöntem, 3 büyük benchmark çalışması.
- **Veri listesi:** multimodal ve çok donörlü aday veriler. En kritik aday **OP3 / NeurIPS 2023:** PBMC, 3 donör, multiome.
- **pertbench:** kendi Python paketimiz. Aynı veri, aynı split'ler ve aynı metriklerle 8 basit modeli çalıştırıyor. Harici modellerin (MultiPert, MultiFlow...) tahminlerini de aynı kodla skorlayabiliyor. CPU'da dakikalar içinde çalışıyor, 10 testi var.

VERİ · GÖREV · MODALİTE	HİÇ DEĞİŞMEZ	PERTURBATION ORTALAMASI	DONÖR-FARKINDA
Sentetik · görülmemiş donör · RNA	8,61	2,14	1,35
Papalexi (THP-1) · görülmemiş replikat · RNA	0,361	0,039	0,039
Papalexi · görülmemiş replikat · protein	0,028	0,007	0,007
Papalexi · görülmemiş perturbation · RNA	0,726	0,579	0,576

Tablo 1. Metrik: en çok değişen 20 özelliğe hata (`mse_top20`, düşük = iyi). En iyi değer yeşil. Donör-farkında model: ContextRidge.

Çıkarılacak iki ders

1. Sentetik veriye kasıtlı olarak donöre özgü bir cevap koyduk. Donör-farkında model bunu yakalayıp hatayı yaklaşık %37 azaltıyor. Yani yöntem, sinyal olduğunda çalışıyor.
2. Papalexi'deki "donör" aslında aynı hücre hattının replikası, bu yüzden donör bilgisi hiçbir şey kazandırmıyor. **Gerçek çok donörlü, multimodal bir veriye ihtiyacımız var.** Toplantıda en çok bunu vurgulamalıyız.

5 Hocanın sorabileceği sorular

Etiket, sorunun ne kadar zorlayıcı olduğunu gösteriyor.

Projenizi bir cümleyle anlatır mısınız?

KOLAY

Yeni bir hastanın kontrol örneğinden, o hastanın hücrelerinin bir perturbation'a cevabını birden fazla molekül katmanında tahmin etmek. Önce var olan yöntemleri adil biçimde karşılaştıracamız, sonra donör bilgisini kullanan bir model geliştireceğiz.

Multimodal veri derken tam olarak neyi kastediyorsunuz?

KOLAY

Aynı hücrede RNA'nın yanında protein (CITE-seq) veya açık kromatin (ATAC) de ölçülmüş olması. Doz ve zaman deney koşulu, modalite değil.

CellFlow zaten donörü kullanıyor. Sizin katkınız ne olacak?

ZOR

CellFlow donörü, o donörün kontrol hücrelerinin *ortalama* RNA profiliyle temsil ediyor ve sadece RNA tahmin ediyor. Katkı olabilecek üç şey var: (1) multimodal çıktı; (2) daha zengin donör temsili: ortalama yerine tüm kontrol dağılımı, multimodal baseline, varsa genotip; (3) görülmemiş donör için basit modellerle sistematik bir benchmark. Bu sonuncusu en güvenli katkı, çünkü alanda eksik.

Derin modeller basit modelleri geçemiyorsa neden model geliştiriyorsunuz?

ZOR

Bu bulgu özellikle "görülmemiş perturbation" görevi için geçerli ve RNA-only modellerle ölçüldü. Multimodal ve donör eksenlerinde henüz kimse sistematik olarak bakmadı. Ya derin model gerçekten fark yaratıyor, ya da yaratmıyor. İki sonuç da raporlanabilir. Model geliştirme ikinci aşama, önce benchmark.

Protein cevabını RNA cevabından tahmin edemez misiniz? O zaman neden multimodal?

ZOR

Tam olarak bunu ölçen bir modelimiz var (`CrossModal`): proteini RNA değişiminden tahmin ediyor. Papalexi'de bu yaklaşım proteini doğrudan ortalamayla tahmin etmekten kötü çıktı: split'e göre protein hatası %24 ile %62 arasında arttı. Yani protein katmanında RNA'dan bağımsız bir sinyal var gibi görünüyor. Bu veride sadece 4 protein var. Daha büyük protein panelli verilerde doğrulamak araştırma sorularımızdan biri.

Hangi veri setiyle başlayacaksınız?

ORTA

Başlangıç: Papalexi ECCITE-seq (RNA+protein, hazır ve çalışıyor) ve MultiFlow'un Perturb-multiome verisi (RNA+ATAC). Bu ikisiyle MultiPert ve MultiFlow'u yeniden üreteceğiz. Donör eksenini için OP3 (PBMC, 3 donör, multiome) ve Parse 10M PBMC (12 donör, 90 sitokin, yalnızca RNA). OP3'te perturbe örneklerde ATAC ölçümü olup olmadığını henüz doğrulamadık.

Neden ham Pearson korelasyonu kullanmıyorsunuz?

ORTA

Hücrelerin baseline profili tahminin büyük kısmını zaten belirliyor. "Hiçbir şey değişmez" diyen model bile ~0,99 korelasyon alıyor. Bu yüzden kontrole göre değişimi (delta) ve en çok değişen genlerdeki hatayı ölçüyoruz.

Görülmemiş donör testini nasıl kuruyorsunuz? Veri sızıntısı olmuyor mu?

ORTA

Bir donörün tüm perturbe örneklerini eğitimden çıkarıyoruz, sadece kontrol örneğini bırakıyoruz. Gerçek hayatta da yeni hastanın kontrolü elimizde olurdu. Her donör sırayla test ediliyor (leave-one-donor-out). Normalizasyon ve özellik seçimi de ileride sadece eğitim verisinde yapılmalı. Bu şu an eksik ve düzeltereğiz.

Neden hücre düzeyinde değil de ortalama profil (pseudobulk) üzerinde çalışıyorsunuz?

ORTA

Alandaki çoğu benchmark (GEARS, Ahlmann-Eltze, OP3) bu düzeyde skorluyor ve CPU'da hızlı çalışıyor. Ama cevabın *dağılımı* da önemli: bazı hücreler cevap verir, bazıları vermez. Bu yüzden dağılım metrikleri (MMD, energy distance) ekleyeceğiz. Flow matching gibi üretici modeller zaten hücre düzeyinde tahmin üretiyor.

Bu dönem sonunda elinizde ne olacak?

ORTA

Aralık sonu hedefi: MultiPert ve MultiFlow'un yeniden üretilmiş sonuçları, bunların en az 2–3 multimodal veri üzerinde basit modellerle karşılaştırılması ve bir ara rapor. Donör analizi ocakta, model geliştirme şubat–mart döneminde.

Hesaplama kaynağınız var mı?

KOLAY

Benchmark ve basit modeller kendi bilgisayarlarımızda çalışıyor. Derin modeller için GPU gerekiyor. Kaggle ve Colab ile başlayabiliriz, ama uzun eğitimler için bölüm sunucusu veya TRUBA erişimi konusunda sizin yönlendirmenize ihtiyacımız var.

İş bölümünüz nasıl?

KOLAY

Bölüm 7'deki rol önerisini anlatın: her model ve veri için bir sorumlu kişi var, benchmark altyapısı ortak.

6 Hocaya soracaklarımız

Toplantıda cevaplananları işaretleyin.

- ☐ Maildeki problem tanımı görselini birlikte üzerinden geçebilir miyiz?
Görsel bize ulaşmadı veya tam okuyamadık. Planın ona uyduğundan emin olmalıyız.
- ☐ Odak benchmark mı, yeni model mi? İkisi de mi?
Takvimi ve riski belirliyor. Önerimiz: önce benchmark, model ikinci aşama.
- ☐ GPU erişimi: bölüm sunucusu veya TRUBA hesabı alabilir miyiz?
MultiPert ve MultiFlow PyTorch ile çalışıyor, eğitim için GPU şart.
- ☐ Bildiğiniz, çok donörlü multimodal bir perturbation verisi var mı? Çalıştığınız gruplardan erişebileceğimiz bir veri?
En büyük darboğazımız bu.
- ☐ Beklenen çıktı ne: tez raporu, poster, workshop makalesi, bioRxiv?
Kalite çıktısını ve yazım takvimini belirliyor.
- ☐ Ne sıklıkla görüşelim? Haftalık kısa rapor mu, iki haftada bir toplantı mı?
- ☐ Kodu ve dokümanları nerede tutalım? GitHub (özel repo) sizin için uygun mu?
- ☐ Mailde bahsettiğiniz diğer hoca da projeye dahil olacak mı?
Hoca bu alanı başka bir hocaya da yazmıştı.

7 Rol dağılımı önerisi

Toplantıdan önce aramızda netleştirelim. Bu sadece bir öneri.

Atay

Benchmark altyapısı ve değerlendirme

- pertbench: split'ler, metrikler, dağılım metrikleri, çok seed desteği
- Harici model tahminlerini skorlama, sonuç tabloları
- Veri sızıntısı kontrolü

Berk

MultiPert yeniden üretimi

- Kodu kurmak, THP-1 sonuçlarını tekrar elde etmek
- Papalexi ve Perturb-multiome'da çalıştırmak
- Hocayla iletişim ve toplantı notları

Alperen

MultiFlow yeniden üretimi

- Kodu kurmak, Perturb-multiome sonuçlarını tekrar elde etmek
- ATAC yerine protein encoder'ı uyarlamasını denemek
- CellFlow'u baseline olarak eklemek (ocak)

Bengisu

Veri ve donör eksen

- OP3, Parse 10M, iPSC CRISPRi verilerini indirmek ve incelemek
- OP3'te perturbe örneklerde ATAC ölçümü var mı?
- Veri yükleyicileri (Atay ile birlikte)

8 Sözlük

Toplantıda geçebilecek terimler.

scRNA-seq

Tek hücre RNA dizileme. Her hücrede her genin kaç kopya RNA'sı olduğunu (count) ölçer.

Perturb-seq / CROP-seq

CRISPR taraması + scRNA-seq. Her hücreye farklı bir guide girer, hangi genin susturulduğu okunur ve hücrenin tüm ifadesi ölçülür.

CRISPR KO / CRISPRi

KO: geni tamamen bozmak. CRISPRi: geni silmeden ifadesini baskılamak.

Guide (sgRNA)

CRISPR'i hedef gene yönlendiren kısa RNA. Bir gen için genelde birkaç guide olur. Biz bunları gen düzeyinde birleştiriyoruz.

CITE-seq / ECCITE-seq / ADT

RNA ile birlikte yüzey proteinlerini DNA etiketli antikolarla ölçmek. ADT = antibody-derived tag (protein count'u).

ATAC-seq / Multiome

ATAC: kromatinin açık bölgelerini ölçer. 10x Multiome: aynı hücrede RNA + ATAC.

Kontrol / NT

Perturbe edilmemiş hücreler. CRISPR deneylerinde "non-targeting" guide alan hücreler.

Donör ve replikat

Donör: farklı insan, farklı genetik. Replikat: aynı hücrenin deneyin tekrarı. Replikat transferi, donör transferinden çok daha kolaydır.

Pseudobulk

Aynı koşuldaki (perturbation × hücre tipi × donör) hücrelerin ortalama profili.

Delta

Perturbe profil eksi kontrol profil. Modelin gerçekten tahmin etmesi gereken şey.

DEG

Differentially expressed gene: perturbation'dan en çok etkilenen genler. "Top-20 DEG metriği" bunlara bakar.

HVG

Highly variable genes: en çok değişkenlik gösteren ~2000 gen. Boyutu azaltmak için kullanılır.

Log-normalizasyon / CLR

RNA için hücre başına 10 bine ölçekleyip log1p almak. Protein için CLR (merkezlenmiş log oran).

Split

Eğitim/test ayrımı. Hangi eksende genellemeyi test ettiğimizi belirler.

Baseline

Karşılaştırma için basit model. Bizde en önemlisi PerturbationMean.

VAE

Variational autoencoder. Veriyi küçük bir latent uzaya sıkıştırıp geri üretir. scGen, CPA ve MultiPert bu aileden.

Adversarial hizalama

Bir ayırt edici ağıın "bu hangi modaliteden geldi?" sorusunu cevaplayamayacağı ortak bir latent uzay öğrenmek.

Flow matching

Gürültüden hedef dağılıma giden bir hız alanı öğrenen üretici model ailesi. CellFlow ve MultiFlow bunu kullanıyor.

Optimal transport (OT)

Bir dağılımı en az maliyetle diğerine taşıma. Kontrol hücrelerini perturbe hücrelerle eşleştirmek için kullanılır (CellOT, scPRAM).

GEARS

Gen ontolojisi grafiği ve GNN ile görülmemiş genetik perturbation'ları tahmin eden model.

Foundation model

Milyonlarca hücreyle önceden eğitilmiş büyük model (scGPT, Geneformer). İnce ayarla perturbation tahmini yapıyor.

MMD / energy distance

İki hücre dağılımının ne kadar farklı olduğunu ölçen metrikler.

9 Toplantı öncesi okuma

Herkes en azından ilk üçünü yapsın.

Bu doküman: özellikle bölüm 2 ve 5	20 dk
MultiPert ve MultiFlow makalelerinin özeti, giriş ve 1. şekli (MultiPert, MultiFlow)	30 dk
Proje dokümantasyonu (Word): bölüm 1 ve bölüm 3	25 dk
Ahlmann-Eltze vd. 2025 (Nat Methods): özet ve ana şekil. "Basit baseline neden önemli" argümanının kaynağı	15 dk
CellFlow: sadece PBMC sitokin / donör bölümü	15 dk

Bu dokümandaki sayılar 29 Eylül 2026 tarihli ön sonuçlardır: CPU'da, pseudobulk düzeyinde ve tek seed ile. Hazırlayan: Emre Atay Tümer.