

Süreç ve iş planı

Hocanın problem tanımı, gönderdiği veriler, iki paralel iz ve okul bilgisayarına geçmeden önce bu hafta neler yapacağımız.

EKİP

Berk · Atay · Alperen · Bengisu

DANIŞMAN

Hilal Kazan

TARİH

1 Ekim 2026

1 Nereye geldik

Son görüşmelerden çıkan kararlar.

KONU	KARAR
Odak	Donör değişimi. Görülmemiş bir donörün tedaviye cevabını, o donörün tedavi öncesi hücrelerinden tahmin etmek.
Veri tipi	Multimodal: RNA + ATAC (ve köprü olarak protein/ADT).
Model	MultiPert üzerine odaklanıyoruz. MultiFlow şimdilik kapsam dışı.
Geliştirme fikri	Multimodal veri entegrasyonu yöntemlerini MultiPert'e taşımak. Kaynak: Fu vd. 2025, Nature Methods entegrasyon benchmark'ı.
Veri	Hoca 3 veri gönderdi. COVID aşı verisiyle başlıyoruz.
Çalışma şekli	İki iz paralel yürüyecek: biri benchmark'a, diğerleri MultiPert'e odaklanacak.
Araçlar	Her şey Python ; R kullanmıyoruz. Ağır eğitimler okul PC'sinde (RTX 5070) veya Kaggle/Colab'de.

Problem (hocanın tanımı)

ARAŞTIRMA SORUSU

Can we predict a multiomic perturbation response in a completely unseen donor using that donor's untreated baseline cells?

	TEDAVİ ÖNCESİ (BASELINE)	TEDAVİ SONRASI
Hasta A, B, C ... (eğitim)	RNA + ATAC	RNA + ATAC
Hasta D (test)	RNA + ATAC	??? tahmin edilecek

Her donör sırayla test donörü oluyor. Buna **leave-one-donor-out (LODO)** diyoruz. Geçmemiz gereken çıta şu basit tahmin: "yeni donör, diğer donörlerin ortalaması kadar değişir" (`PerturbationMean`). Model bunu geçemiyorsa, donöre özgü bir şey öğrenememiş demektir.

2 Hocanın gönderdiği veriler

Üçünü de inceledik. Ayrıntılar: docs/07_hocanın_veri_setleri.md

	COVID aşısı Zhang vd., Nat Immunol 2023	Nöroblastom Yu vd., Nat Genet 2025	Pediyatrik AML Lambo vd., Cancer Cell 2023
"Perturbation"	Aşı: gün 0 → 2, 10, 28	Kemoterapi öncesi → sonrası	Tanı → remisyon / nüks
Donör	6 sağlıklı	22 hasta	28 hasta
Modalite	CITE-seq (RNA+ADT) ve ASAP-seq (ATAC+ADT); 173 ortak protein	snRNA + snATAC (ayrı), WGS	scRNA + scATAC (ayrı)
Erişim	Açık (Zenodo), ~6,3 GB	Kısmen açık (HTAN, CELLxGENE)	İşlenmiş veri açık (GEO)
Rol	Başlangıç verisi: temiz tasarım, pipeline'ı kurmak için	Ana hedef / ikinci aşama: probleme en birebir uyan	Opsiyonel: "remisyon" ilacın cevabı değil

EN ÖNEMLİ NOKTA

Üç veride de RNA ve ATAC aynı hücrede ölçülmemiş. COVID verisinde CITE ve ASAP farklı hücrelerde yapılmış. İkisini bağlayan tek şey her iki assay'de de ölçülen proteinler (ADT).

MultiPert ise her hücrede iki modalitenin birlikte olduğunu varsayıyor, yani bu verilere olduğu gibi uygulanamaz. Önce modaliteleri ortak bir uzaya taşıyan bir **entegrasyon katmanı** gerekiyor. Hocanın Fu vd. benchmark'ını önermesinin sebebi bu.

3 İki iz

Paralel yürüyecek, 3. haftada birleşecek. Ayrıntılar: docs/08_iki_iz_plani.md

İz A: MultiPert

Perturbation ve donör modülü

- MultiPert'i orijinal haliyle çalıştırmak, makaledeki sonuçları yeniden üretmek
- Sonuçları bizim delta metrikleriyle yeniden skorlamak (makaledeki metrik şişkin sonuç veriyor)
- Donör bazlı bölme ve donör içi eşleşme eklemek
- Hücre eşleşmesi gerektirmeyen, dağılım düzeyinde bir versiyon: baseline dağılımı + donör bilgisi → tedavi sonrası dağılım

İz B: Entegrasyon benchmark'ı

MultiPert'in yeni omurgasını seçmek

- Fu vd. 2025'i okumak: mosaic ve diagonal bölümleri, metrikler
- Python'da çalışan adayları COVID verisinde denemek: **MIDAS, MultiVI, GLUE, totalVI**
- İki şeyi ölçmek: modaliteler iyi hizalanıyor mu, **donör farkı korunuyor mu**
- En iyi 1-2 yöntemi İz A'ya teslim etmek

Fu vd.'den bizim verilere uyan yöntemler

VERİ YAPISI	BİZDEKİ KARŞILIĞI	ÖNDE ÇIKAN YÖNTEMLER
Mosaic: ortak bir köprü modalite var	COVID (köprü: ADT)	MIDAS (eksik modaliteyi tamamlamada en iyi), MultiVI (en sağlam)

VERİ YAPISI	BİZDEKİ KARŞILIĞI	ÖNDE ÇIKAN YÖNTEMLER
Diagonal: hiç eşleşme yok	Nöroblastom, AML	GLUE (hücre hizalamada açık ara önde)

DİKKAT

Entegrasyon yöntemleri, kendilerine "batch" olarak verilen bilgiyi siler. **Donörü batch olarak vermemeliyiz**, çünkü korumak istediğimiz şey tam olarak donör farkı. Batch olarak assay (CITE/ASAP) veya kütüphane verilmeli.

Hedef mimari

- Entegrasyon omurgası** (İz B): Her hücreyi, hangi modalite ölçülmüş olursa olsun, ortak bir latent uzaya taşır.
- Donör temsili**: Donörün baseline hücrelerinin latent dağılımından bir özet vektör çıkarılır.
- Perturbation modülü** (İz A, MultiPert'ten): baseline + donör + gün → tedavi sonrası latent dağılımı.
- Decoder'lar**: RNA, ATAC ve ADT profillerini geri üretir. Değerlendirme LODO ile yapılır.

4 Rol dağılımı (öneri)

Benchmark'a bir kişi odaklanacak. Aşağıdaki dağılımı aramızda netleştirelim.

Kişi	İz	BU HAFTA
Atay	Altyapı + baseline'lar	COVID verisini indirip dönüştürmek, LODO baseline tablosunu çıkarmak, repo ve ortam kurulumu
Berk	İz A	MultiPert makalesi ve kodu (<code>models.py</code> , <code>trainer.py</code>), orijinal haliyle çalıştırmak
Alperen	İz A	MultiPert'in donör split'ine uyarlanması: <code>data_loader.py</code> , eşleşme ve bölme mantığı. totalVI / MultiCPA okuması
Bengisu	İz B (benchmark)	Fu vd. 2025 okuması, MIDAS / MultiVI / GLUE kısa listesi, COVID verisinin yapısını incelemek

5 Okul PC'si olmadan bu hafta

Başlangıç işlerinin çoğu GPU istemiyor. Kendi bilgisayarlarımızda başlayabiliriz.

İş	NEREDE?
COVID verisini indirmek (~6,3 GB), <code>.rds</code> → h5ad dönüşümü	Kendi bilgisayarımız . ASAP dosyası için ~16 GB+ RAM gerekebilir
Veriyi incelemek: donör × gün × hücre tipi tabloları	Kendi bilgisayarımız
LODO baseline'ları (ilk sonuçlar)	Kendi bilgisayarımız , dakikalar sürer
MultiPert'i orijinal küçük veride çalıştırmak (~9 bin hücre)	Kendi bilgisayarımız (CPU) veya Kaggle
MultiVI / GLUE / MIDAS'ı 100 bin+ hücrede eğitmek	Kaggle (haftada ~30 saat ücretsiz GPU) veya Colab. Sonra okul PC'si

R kullanmak zorunda mıyız? Hayır.

- COVID verisi Seurat (R) formatında, ama Python'daki `py8rds` ile R olmadan okunuyor. Yedeği `readseurat`, o da olmazsa tek seferlik bir Colab dönüşümü.
- MultiPert (PyTorch), scvi-tools (MultiVI, totalVI), scglue (GLUE) ve MIDAS'ın hepsi Python.
- Tek kaybımız Seurat v5 Bridge, çünkü R gerektiriyor. Aynı kategoride üst sıralarda MIDAS ve MultiVI olduğu için sorun değil.

Hazır olan altyapı

Kendi yazdığımız **pertbench** paketi ve COVID verisi için sırayla çalıştırılacak scriptler (`scripts/covid/`):

SCRIPT	NE YAPAR
<code>00_check_env.py</code>	Kütüphaneleri ve GPU'yu kontrol eder (RTX 5070 için PyTorch cu128 gerekir)
<code>01_download.py</code>	COVID verisini Zenodo'dan indirir, bütünlüğünü kontrol eder
<code>02_inspect_rds.py</code>	Seurat dosyasının içindeki assay'leri ve metadata sütunlarını R olmadan listeler
<code>03_convert.py</code>	Her assay'i ayrı bir h5ad'e çevirir
<code>04_run_lodo.py</code>	6 fold LODO: 5 donörle eğit, 6.'nın gün 2/10/28 profilini RNA, ADT ve ATAC'ta tahmin et

Akış sahte veriyle uçtan uca test edildi, 12 test geçiyor. Gerçek veriyle henüz çalıştırılmadı.

6 Takvim

ZAMAN	İŞ	KİM
1. hafta	Okuma + veri hazırlığı MultiPert ve Fu vd. okuması. COVID verisinin indirilmesi ve dönüştürülmesi. İlk LODO baseline tablosu.	Hepimiz
Hafta sonu	İç toplantı Herkes 5 dakika anlatır. Hocaya götürülecek fikirler seçilir.	Hepimiz
2. hafta	İlk deneyler MultiPert'in yeniden üretimi ve yeniden skorlanması. Entegrasyon adaylarının COVID verisinde ilk denemesi.	İz A / İz B
3. hafta	Birleştirme Seçilen omurga + donör koşullu perturbation modülü. İlk LODO sonuçları.	Hepimiz
Sonra	Nöroblastom 22 hastalık veriyle asıl deney.	Hepimiz

Hocayla bir sonraki görüşmeye götüreceğimiz

- COVID verisinin yapısı: hücre sayıları, donör × gün × hücre tipi tablosu
- LODO baseline tablosu: ilk somut sayılar
- MultiPert'in yeniden üretimi ve bizim metriklerle yeniden skorlanması
- Entegrasyon için kısa liste ve ilk karşılaştırma
- Önerilen mimari

Mini sözlük

LODO (leave-one-donor-out)

Her donör sırayla test edilir, diğerleriyle eğitilir.

Mosaic entegrasyon

Bazı hücrelerde bir modalite eksik, ama ortak bir köprü modalite var (COVID'de ADT).

Diagonal entegrasyon

Modaliteler tamamen farklı hücrelerde, hiç ortak ölçüm yok (nöroblastom, AML).

Pseudobulk

Donör × gün × hücre tipi grubundaki hücrelerin ortalama profili.

Delta

Tedavi sonrası eksi tedavi öncesi profil. Asıl tahmin edilen şey.

ADT

Antikorla ölçülen yüzey proteinleri (CITE-seq / ASAP-seq).

Kaynak dokümanlar proje klasöründe: `docs/07_hocanın_veri_setleri.md`, `docs/08_iki_iz_plani.md`, `docs/09_okul_pc_calisma_plani.md`. Hazırlayan: Emre Atay Tümer.